Pós-Graduação em Machine Learning,
Deep Learning e Inteligência Artificial

Operacionalização de Modelos com MLOps [26E1_2]

Prof. Ícaro Augusto Maccari Zelioli

Avaliação de Risco de Crédito

12 de abril de 2026

Projeto: Operacionalização de Modelos com MLflow e Streamlit

Aluno:

- Fabio Ferreira Figueiredo

Link GitHub:

https://github.com/fabioffigueiredo/pd_operacionaliza-o_modelos-_mlops

Vídeo de demonstração:

Arquivo local no repositório: `mlflow+streamlit_mlops.mp4`

Backup Google Drive: https://drive.google.com/file/d/11Yn6D01kEwuc6N-__t40ZlxxyOoEa-uM/view?usp=sharing

Descrição do Problema, MLOps e Pipeline

Contexto do Problema:

O dataset **Give Me Some Credit** contém informações de aproximadamente 150.000 tomadores de crédito. O objetivo é prever inadimplência severa nos próximos 2 anos, usando a variável alvo binária `SeriousDlqin2yrs`.

Nesta segunda etapa, o foco deixa de ser apenas comparação de modelos e passa a ser **operacionalização**: organização de código, rastreabilidade com MLflow, seleção controlada de modelo campeão e inferência reproduzível via Streamlit.

O contexto regulatório continua central. Em crédito, a solução precisa equilibrar desempenho, interpretabilidade e governança, considerando exigências associadas à LGPD e à transparência esperada em decisões automatizadas.

Guia de Navegação — Rubrica de Avaliação

> **Nota ao avaliador:** a estrutura do relatório foi reorganizada para seguir diretamente a ordem da rubrica do professor. Cada competência aparece como uma seção principal, facilitando a validação do que foi demonstrado em cada critério.

Fase da Rubrica	Competência Avaliada	Seção do Relatório
Competência 1	Estruturação do projeto, contexto, planejamento e transição do notebook para entrega	Seção 1
Competência 2	Pipelines de dados, qualidade, features e análise de redução de dimensionalidade	Seção 2
Competência 3	Experimentos reprodutíveis, comparação de abordagens e rastreamento com MLflow	Seção 3
Competência 4	Operacionalização, inferência, métricas de negócio, monitoramento, drift e re-treino	Seção 4
Fechamento	Conclusões e próximos passos	Seção 5

1. Competência 1 — Estruturação do Projeto, Contexto e Entrega

1.1 Introdução e Mudança de Paradigma

O PD1 focou na experimentação isolada de modelos dentro de um Jupyter Notebook, comparando algoritmos (Perceptron, Árvore de Decisão, Random Forest) para o problema de credit scoring. O PD2 representa uma mudança fundamental de perspectiva: do cientista de dados que experimenta para o **engenheiro de ML que opera sistemas**.

O foco deixa de ser "qual modelo tem o melhor F1?" e passa a ser: como construir um sistema de ML **reprodutível, rastreável e operacionalizável** em produção?

Esta transição exigiu a reestruturação completa do código em módulos Python independentes, a integração com MLflow para rastreamento de experimentos, a comparação sistemática de técnicas de redução de dimensionalidade, e o deploy do modelo via Streamlit.

Objetivo técnico: construir um pipeline reproduzível para previsão de `SeriousDlqin2yrs`, com separação clara entre preparo de dados, treinamento, rastreamento experimental e inferência.

Métricas de negócio associadas: reduzir o risco de **falsos negativos** (aprovar quem tende a inadimplir), sem ignorar o custo de **falsos positivos** (recusar bons pagadores), respeitando o contexto regulatório de crédito.

1.2 Reestruturação do Código: Do Notebook ao Sistema Modular

1.2.1 Problemas do Notebook

O notebook `projeto_credito_supervisionado.ipynb` (2.094 linhas, 498 KB) apresentava problemas típicos para operacionalização:

- **Estado global implícito:** variáveis de uma célula afetavam silenciosamente as seguintes
- **Não-reprodutibilidade:** ordem de execução das células importava; células podiam ser executadas fora de ordem
- **Impossibilidade de teste unitário:** lógica de negócio misturada com visualizações e narrativa
- **Sem versionamento de lógica:** mudanças no pré-processamento ou hiperparâmetros não eram rastreadas
- **Impossibilidade de integração:** nenhum script externo podia importar funções do notebook

1.2.2 Arquitetura Modular Adotada

```
src/
├── data_processing.py    # Separação de concerns: ingestão e pré-processamento
└── train.py              # Orquestração do treinamento com MLflow
config/
└── pipeline.yaml         # Configuração centralizada (fonte única de verdade)
app/
└── app.py                # Camada de apresentação desacoplada da lógica de ML
```

Princípio central adotado: cada módulo tem uma única responsabilidade e pode ser testado independentemente. O `data_processing.py` pode ser importado tanto pelo `train.py` quanto por um script de inferência batch, sem copiar código.

1.2.3 Configuração Centralizada

O arquivo `config/pipeline.yaml` elimina os "magic numbers" espalhados pelo código. Hiperparâmetros, paths, e configurações de validação cruzada estão em um único lugar. Isso permite: - Reproduzir experimentos com configurações diferentes sem editar código - Auditar facilmente quais parâmetros foram usados em cada experimento (via MLflow) - Facilitar o processo de CI/CD: pipelines automatizados leem o YAML

---

2. Competência 2 — Pipelines de Dados, Features e Redução de Dimensionalidade

2.1 Qualidade de Dados e Tratamento

2.1.1 Diagnóstico de Problemas

A análise exploratória do PD1 identificou dois tipos principais de problemas:

Feature	Problema	Proporção afetada
`MonthlyIncome`	Valores ausentes (NaN)	~20% dos registros
`NumberOfDependents`	Valores ausentes (NaN)	~2,5% dos registros

Feature	Problema	Proporção afetada
`DebtRatio`	Outliers absurdos (> 1000)	< 1% dos registros
`RevolvingUtilizationOfUnsecuredLines`	Outliers (> 1.0 impossível fisicamente)	< 1% dos registros

2.1.2 Estratégia de Tratamento: Outliers por Capping

Decisão técnica: Capping no percentil 99 para `DebtRatio` e `RevolvingUtilizationOfUnsecuredLines`.

Justificativa: - `DebtRatio` representa a razão entre pagamentos de dívida e renda. Valores acima de 1.000 são matematicamente impossíveis em contextos reais (indicam erros de entrada de dados). - O capping preserva a distribuição da população real enquanto elimina o efeito distorcivo desses outliers no `StandardScaler` — sem capping, a padronização comprimiria toda a distribuição real em um intervalo minúsculo. - A alternativa (remoção dos registros) eliminaria ~1.500 linhas potencialmente válidas onde apenas uma feature apresenta problema.

Limitação documentada: O percentil 99 foi calculado no dataset completo antes do `train_test_split`. Em produção, o threshold deveria ser calculado exclusivamente no conjunto de treino e armazenado como parâmetro do pipeline. Esta simplificação é aceitável no contexto acadêmico e está documentada no código.

2.1.3 Estratégia de Tratamento: Valores Ausentes

Decisão técnica: `SimpleImputer(strategy='median')` dentro do sklearn Pipeline.

Justificativa: - A mediana é mais robusta que a média na presença de outliers residuais (após o capping, ainda pode haver valores extremos legítimos em `MonthlyIncome`). - Imputação dentro do Pipeline garante que a mediana é calculada APENAS no conjunto de treino e aplicada ao conjunto de teste — evitando data leakage. - A alternativa (remoção de linhas com NaN) eliminaria ~30.000 registros (~20% do dataset), reduzindo severamente a representatividade da amostra.

2.1.4 Impacto na Generalização

A presença de 20% de valores ausentes em `MonthlyIncome` representa um risco estrutural: se a ausência de renda estiver correlacionada com o comportamento de pagamento (hipótese plausível — clientes sem renda declarada podem ser mais propensos à inadimplência), a imputação pela mediana introduz um viés. Esta limitação é irresolvível pelos dados disponíveis e deve ser documentada para o time de negócio.

2.2 Redução de Dimensionalidade: Análise Comparativa

2.2.1 Motivação e Contexto

Com apenas 10 features e 150.000 registros, este dataset não sofre da maldição da dimensionalidade. A aplicação de redução de dimensionalidade serve aqui como experimento comparativo explícito, conforme exigido pela rubrica do PD2, não como necessidade técnica primária.

Foram testadas duas técnicas com características complementares: **PCA** (não supervisionada, baseada em variância) e **LDA** (supervisionada, baseada em separabilidade de classes).

2.2.2 PCA — Análise de Componentes Principais

Configuração: `PCA(n_components=0.95)` — sklearn seleciona automaticamente o número mínimo de componentes que explicam ≥ 95% da variância total.

Resultado observado: 9 componentes para atingir 95% da variância explicada. Isso confirma que, apesar de correlações entre as features de atraso, o espaço de features preserva informação relativamente distribuída entre múltiplas dimensões.

Impacto no F1-Score: Espera-se desempenho similar ao baseline ou ligeiramente inferior, pois a compressão de 10 para ~8 dimensões é modesta e o RF é robusto a correlações.

Impacto na interpretabilidade: Crítico. Os componentes principais são combinações lineares de todas as features originais. A feature `RevolvingUtilizationOfUnsecuredLines` — identificada no PD1 como o nó raiz da árvore de decisão mais importante — não existe mais como entidade identificável no espaço transformado. Isso é incompatível com os requisitos da **LGPD Art. 20** (direito à explicação de decisões automatizadas) e com as resoluções do **BACEN** que exigem transparência em modelos de crédito.

Conclusão sobre PCA: Tecnicamente viável como compressão, mas problemático do ponto de vista regulatório para um sistema de crédito no contexto brasileiro.

2.2.3 LDA — Análise Discriminante Linear

Configuração: `LDA(n_components=1)`.

Limitação matemática: Para classificação binária (2 classes), o máximo de componentes discriminantes é `min(n_classes - 1, n_features) = 1`. Esta não é uma escolha — é uma restrição algorítmica.

Impacto no F1-Score: Espera-se **queda significativa**. Projetar 10 dimensões em 1 único eixo, mesmo que esse eixo seja o que maximiza a separação entre classes, resulta em perda substancial de informação preditiva. Features como `MonthlyIncome` e `age` capturam aspectos do risco que são ortogonais entre si — colapsá-las em uma dimensão cria confusão.

Vantagem sobre PCA: O componente LDA tem interpretação: é a direção no espaço de features que melhor separa adimplentes de inadimplentes. Os coeficientes da transformação LDA indicam quais features mais contribuem para essa separação.

Conclusão sobre LDA: Inapropriado para este problema na forma univariada. Útil como análise exploratória (visualização 1D da separabilidade das classes), mas não como etapa de pré-processamento para produção.

2.2.4 Comparativo: Com vs. Sem Redução

Experimento	Redução	F1-Score (teste)	ROC-AUC	Interpretabilidade	Treino
RF + PCA	9 de 10 componentes (~95% var.)	**0.4354**	0.8555	Baixa (componentes latentes)	24.7 min
RF Baseline	Nenhuma	0.4308	0.8572	Alta (feature importances diretas)	19.4 min
RF + LDA	1 componente	0.3494	0.8156	Média (1 eixo interpretável)	14.9 min
DT Baseline	Nenhuma	0.3408	0.8544	Muito Alta (regras auditáveis)	45 seg

Análise da distribuição de variância (PCA): Com o capping adequado de outliers aplicado, as features passaram a ter distribuição de variância quase uniforme: PC1=21%, PC2=17%, PC3=13%, PC4=11%, PC5=8%, PC6=7%, PC7=7%, PC8=6%, PC9=6%, PC10=5%. São necessários **9 de 10 componentes** para atingir 95% da variância — evidência de que as features de crédito capturam aspectos ortogonais e independentes do comportamento financeiro.

---

3. Competência 3 — Experimentos Reprodutíveis com MLflow

3.1 Planejamento Experimental

Foram definidos quatro experimentos comparativos com a mesma base de treino/teste e a mesma métrica primária (`F1-Score`), para isolar o impacto da redução de dimensionalidade e comparar custo, desempenho e interpretabilidade:

Experimento	Objetivo
`RF_sem_reducao_baseline`	baseline forte sem compressão de features
`RF_com_PCA`	testar compressão não supervisionada com preservação de variância
`RF_com_LDA`	testar redução supervisionada em classificação binária
`DT_sem_reducao_baseline`	comparar ensemble vs. modelo altamente auditável

Todos os experimentos foram executados com validação cruzada estratificada, `GridSearchCV` e rastreamento no MLflow.

3.2 Rastreamento e Reprodutibilidade com MLflow

O `train.py` registra, em cada run:

- hiperparâmetros efetivos do modelo
- métricas de validação cruzada e holdout
- tempo de treino
- artefato serializado do pipeline treinado

Esse desenho garante que a seleção do campeão não dependa de memória operacional ou execução manual dispersa: cada decisão fica associada a um `run_id` recuperável e auditável.

3.3 Seleção e Justificativa do Modelo Campeão

3.3.1 Critérios de Seleção

A escolha do modelo campeão considerou quatro dimensões:

1. **Performance preditiva:** F1-Score no conjunto de teste holdout (métrica primária)
2. **Custo computacional:** tempo de treino e inferência
3. **Interpretabilidade:** capacidade de explicar predições individuais
4. **Viabilidade em produção:** compatibilidade com requisitos regulatórios

3.3.2 Justificativa Técnica

O **Random Forest com PCA (9 componentes)** foi o modelo campeão factual deste ciclo experimental. Ele obteve o maior F1-Score no holdout (`0.4354`) e, por isso, foi a run persistida no MLflow e operacionalizada no Streamlit por meio do `run_id` salvo em `models/champion_run_id.txt`.

Melhor desempenho na métrica primária: Pelo critério definido para seleção do campeão, o `RF + PCA` superou o `RF baseline` por pequena margem absoluta (`0.4354` vs. `0.4308` em F1). Como o objetivo da comparação experimental era maximizar a métrica primária mantendo o pipeline reproduzível, esta foi a escolha adotada para a demonstração funcional.

Trade-off explícito de interpretabilidade: O ganho de performance veio acompanhado de perda de explicabilidade direta. Após o PCA, as importâncias do Random Forest passam a refletir componentes latentes, e não mais as features originais. Em um contexto regulado de crédito, esse é um custo real e precisa ser reconhecido tecnicamente.

Custo computacional ainda aceitável: O experimento com PCA treinou em `24.7 min`, contra `19.4 min` do baseline sem redução. Há aumento de custo, mas ele permanece aceitável para um fluxo acadêmico e para ciclos controlados de re-treino offline.

Decisão de engenharia, não apenas de métrica: Embora o campeão factual deste projeto seja `RF + PCA`, o `RF baseline` segue como forte desafiante por combinar F1 muito próximo, ROC-AUC ligeiramente superior (`0.8572` vs. `0.8555`) e interpretabilidade melhor. Em produção regulada, essa alternativa continuaria plenamente defensável caso a prioridade passasse de performance marginal para auditoria e transparência.

3.3.3 Comparação com o PD1

O modelo campeão do PD1 obteve F1-Score de 0.4328. O PD2 não apenas reproduziu esse valor (RF baseline: 0.4308, diferença de apenas 0.002) como o **superou levemente com RF+PCA: F1=0.4354**. A diferença mínima do baseline é esperada — o split treino/teste do PD2 usa `stratify=y` com `random_state=42`, e o capping adicional de outliers (MonthlyIncome, features de atraso com sentinela 98) muda levemente a distribuição dos dados.

A vantagem do PD2 sobre o PD1 não está no F1-Score, mas na **rastreabilidade**: cada resultado é reprodutível via `run_id` do MLflow, com parâmetros, dados e código completamente documentados.

---

4. Competência 4 — Operacionalização, Inferência e Monitoramento

4.1 Persistência e Versionamento

O modelo campeão é persistido via `mlflow.sklearn.log_model()` como artefato da run MLflow. Esta abordagem garante:

- **Rastreabilidade:** cada modelo no MLflow está associado ao experimento, parâmetros e métricas que o geraram
- **Reprodutibilidade:** o MLflow registra a versão do sklearn e metadados do ambiente de execução
- **Versionamento:** múltiplas versões do modelo coexistem no `mlruns/`, identificadas por `run_id`

4.2 Interface de Inferência (Streamlit)

O aplicativo Streamlit (`app/app.py`) carrega o modelo via `mlflow.sklearn.load_model(model_uri)` e expõe uma interface web com:

- **Sidebar:** formulário com todos os 10 campos de features, com valores padrão razoáveis e texto de ajuda contextualizado
- **Resultado:** classificação "APROVADO (Baixo Risco)" ou "REPROVADO (Alto Risco)" com destaque visual
- **Probabilidades:** gráfico de barras mostrando a distribuição de probabilidade entre as duas classes
- **Explicabilidade:** gráfico de importância de features (disponível apenas para RF sem redução, com mensagem explicativa para modelos com PCA/LDA)

O carregamento usa `@st.cache_resource` para carregar o modelo uma única vez por sessão do servidor, independentemente do número de usuários simultâneos.

Vídeo de demonstração da operação simulada: - Arquivo versionado no repositório: `mlflow+streamlit_mlops.mp4` - Backup no Google Drive: https://drive.google.com/file/d/11Yn6D01kEwuc6N-__t40ZlxxyOoEa-uM/view?usp=sharing

4.3 Impacto de Negócio dos Tipos de Erro

Tipo de Erro	Predição	Realidade	Impacto
Falso Negativo	Adimplente	Inadimplente	Aprovação de crédito para quem vai inadimplir → perda financeira direta
Falso Positivo	Inadimplente	Adimplente	Recusa de crédito a bom pagador → perda de receita, risco reputacional

Assimetria de custo: Em crédito, o Falso Negativo tipicamente tem custo maior que o Falso Positivo. O F1-Score trata os dois igualmente — em produção, seria apropriado ponderar pelo custo relativo de cada erro e ajustar o threshold de decisão da probabilidade (padrão: 0.5).

4.4 Métricas Técnicas Monitoradas

Métrica	Propósito	Alerta
F1-Score (janela 30 dias)	Degradação do modelo	Queda > 5% vs. baseline
ROC-AUC	Capacidade discriminativa	Queda > 0.03
Taxa de inadimplência prevista	Sanidade do modelo	Desvio > 20% da média histórica
Latência de inferência	Performance operacional	P99 > 500ms

4.5 Detecção de Data Drift

Data drift ocorre quando a distribuição das features de entrada em produção diverge da distribuição do conjunto de treino, degradando a performance sem que o modelo "saiba" disso.

Estratégias propostas:

PSI (Population Stability Index): Para cada feature contínua, calcular o PSI entre a distribuição de treino e janelas de 30 dias de produção. - PSI < 0.1: distribuições estáveis (sem ação) - 0.1 ≤ PSI < 0.25: mudança moderada (investigar) - PSI ≥ 0.25: mudança severa (re-treino prioritário)

Teste de Kolmogorov-Smirnov: Para features numéricas, KS-test com p-value < 0.01 indica drift significativo.

Monitoramento da distribuição do target: Se a taxa de inadimplência observada (após 90 dias de carência) divergir significativamente da taxa prevista, o modelo está descalibrado.

Gatilhos de re-treino: 1. PSI ≥ 0.25 em qualquer feature crítica (`RevolvingUtilizationOfUnsecuredLines` , `DebtRatio`) 2. F1-Score em produção < 0.35 por duas semanas consecutivas 3. Mudanças macroeconômicas significativas (ex: mudança da taxa Selic, crises econômicas)

4.6 Estratégia de Re-treino Contínuo

O MLflow facilita o re-treino controlado: cada ciclo de re-treino cria novos `run_id` s que permitem comparar a versão nova com a versão em produção antes de fazer o swap. O fluxo recomendado:

```
Dados novos → train.py → MLflow (nova run) →
Comparação de métricas (novo vs. atual) →
Aprovação → Atualizar champion_run_id.txt →
Reiniciar Streamlit
```

---

5. Conclusões

5.1 O que Este Projeto Demonstrou

1. **A transição do notebook para sistema modular é uma mudança de mindset**, não apenas de formato. Módulos separados forçam a explicitação de interfaces, contratos e responsabilidades que o notebook escondia.
2. **Redução de dimensionalidade exige análise de trade-off, não adesão automática.** Com 10 features e 150.000 registros, o LDA degradou fortemente o desempenho e o PCA trouxe ganho marginal de F1 ao custo de interpretabilidade. A evidência experimental mostra que performance isolada e auditabilidade podem apontar para escolhas diferentes.
3. **Rastreamento é infraestrutura, não burocracia.** O MLflow elimina a pergunta "qual versão do modelo está em produção?" — a resposta está sempre no `run_id` registrado, com todos os parâmetros e métricas associados.
4. **Deploy não é o fim do ciclo de ML, é o começo.** O sistema de monitoramento proposto (PSI, KS-test, F1 em produção) fecha o loop entre dados, modelo e negócio — tornando o sistema verdadeiramente operacional.

5.2 Próximos Passos Sugeridos

- Implementar pipeline de monitoramento automatizado com alertas (ex: via Airflow ou scheduled job)
- Explorar modelos com maior interpretabilidade nativa (ex: LGBM com explicações SHAP)
- Adicionar autenticação e logging de predições ao Streamlit para auditoria regulatória
- Containerizar o sistema (Docker) para deploy em ambiente de produção real

---

Referências

- LGPD — Lei Geral de Proteção de Dados (Lei 13.709/2018), Artigo 20
- Banco Central do Brasil — Resolução CMN nº 4.557/2017 (gestão de riscos)
- Kaggle: Give Me Some Credit Dataset — https://www.kaggle.com/datasets/brycecf/give-me-some-credit-dataset
- MLflow Documentation — https://mlflow.org/docs/latest/
- Scikit-learn User Guide: Pipelines and composite estimators
- Grus, Joel. *Data Science from Scratch*. O'Reilly, 2019.
- Kleppmann, Martin. *Designing Data-Intensive Applications*. O'Reilly, 2017.